

## AGRUPAMENTO DE MÚSICAS POR SIMILARIDADE SONORA (K-MEANS E HIERARCHICAL CLUSTERING) - ANÁLISE DOS GRÁFICOS

BEATRIZ DA COSTA LAURO


Estudante Universitário, Universidade do Estado de Minas Gerais, beatriz.2148647@discente.uemg.br

### Elbow Method (Inertia) — Método do Cotovelo

O gráfico *Elbow (Inertia) — K-Means* mede a inércia, também chamada de soma dos quadrados internos, para cada quantidade de grupos ( $k$ ) testada no modelo. Em outras palavras, ele mostra o quanto os dados estão próximos do centro de seus respectivos clusters, conforme o número de agrupamentos aumenta. Cada ponto do gráfico representa o valor da inércia para um determinado número de clusters. Naturalmente, a inércia tende a diminuir à medida que mais clusters são criados, pois os grupos ficam menores e mais homogêneos. No entanto, a redução deixa de ser significativa a partir de certo ponto, é o que chamamos de “cotovelo” da curva.

O ponto onde ocorre esse cotovelo indica o valor ideal de ‘ $k$ ’, ou seja, a quantidade mais adequada de grupos a ser formada. Antes desse ponto, o aumento do número de clusters melhora muito o ajuste do modelo; depois dele, o ganho é mínimo e pode levar a uma clusterização excessiva, sem ganhos reais de interpretação.

No contexto da análise musical, o gráfico do cotovelo ajuda a identificar quantos perfis sonoros distintos existem naturalmente no conjunto de dados. Por exemplo, o “cotovelo” pode indicar a presença de três grandes grupos de músicas, dançantes, calmas e acústicas, revelando diferentes estilos ou atmosferas dentro da base analisada.




### Silhouette Score por k

O gráfico *Silhouette Score por k — K-Means* apresenta uma medida quantitativa da qualidade dos agrupamentos formados pelo algoritmo. O silhouette score avalia simultaneamente a coerência interna de cada cluster (quão próximas as músicas de um mesmo grupo estão entre si) e a separação entre os clusters (o quanto os grupos são diferentes uns dos outros).

Os valores dessa métrica variam entre  $-1$  e  $+1$ . Pontuações próximas de  $+1$  indicam que os clusters estão bem definidos, com músicas muito semelhantes dentro de cada grupo e bem distintas entre grupos diferentes. Valores próximos de  $0$  mostram sobreposição entre os clusters, sugerindo que os limites entre eles não são muito claros. Já valores negativos indicam que muitas músicas podem ter sido atribuídas ao cluster errado, o que evidencia uma segmentação ineficiente.

Na interpretação do gráfico, o número de clusters ( $k$ ) correspondente ao maior valor de silhouette score é geralmente considerado o mais adequado, pois representa o melhor equilíbrio entre coesão interna e separação entre grupos. Assim, o gráfico complementa o método do cotovelo, oferecendo uma métrica mais objetiva para determinar o valor ideal de  $k$ .

No contexto das músicas, o Silhouette Score mostra quantos grupos sonoros distintos realmente existem no conjunto de dados. Por exemplo, se o valor máximo ocorrer em  $k = 4$ , isso pode indicar a presença de quatro grandes perfis musicais, como faixas dançantes, calmas, instrumentais e energéticas, refletindo diferentes estilos e atmosferas dentro da base analisada.



### Scatter Plot (PCA) — Visualização dos Clusters


O gráfico *K-Means ( $k = \text{valor ótimo}$ ) — projeção PCA* utiliza a Análise de Componentes Principais (PCA) para representar visualmente os agrupamentos formados pelo algoritmo K-Means em um plano bidimensional. O PCA é uma técnica de redução de dimensionalidade que transforma diversas características de áudio, como energia, dançabilidade, valência e acusticidade, em duas componentes principais capazes de concentrar a maior parte da variação dos dados.

Neste gráfico, cada ponto representa uma música do conjunto de dados, enquanto as cores correspondem aos clusters definidos pelo K-Means. Assim, músicas com cores

iguais pertencem ao mesmo grupo sonoro, indicando que compartilham padrões semelhantes em suas características.

A interpretação visual desse gráfico permite observar como os grupos se distribuem no espaço, revelando o grau de separação entre os perfis musicais. É normal que alguns clusters se sobreponham parcialmente, pois a projeção reduz as informações multidimensionais para apenas duas dimensões. Mesmo assim, quando os pontos coloridos formam regiões bem distintas, significa que o modelo conseguiu capturar diferenças claras entre estilos ou tipos de músicas.

No contexto da análise musical, cada cor representa um perfil sonoro específico, por exemplo, músicas agitadas e dançantes, faixas mais calmas e acústicas, ou ainda composições instrumentais. Quando há uma separação visível entre as cores, isso indica que o modelo conseguiu distinguir com sucesso os diferentes estilos ou atmosferas musicais presentes no conjunto analisado.



### Boxplots por Feature (para cada atributo de áudio)

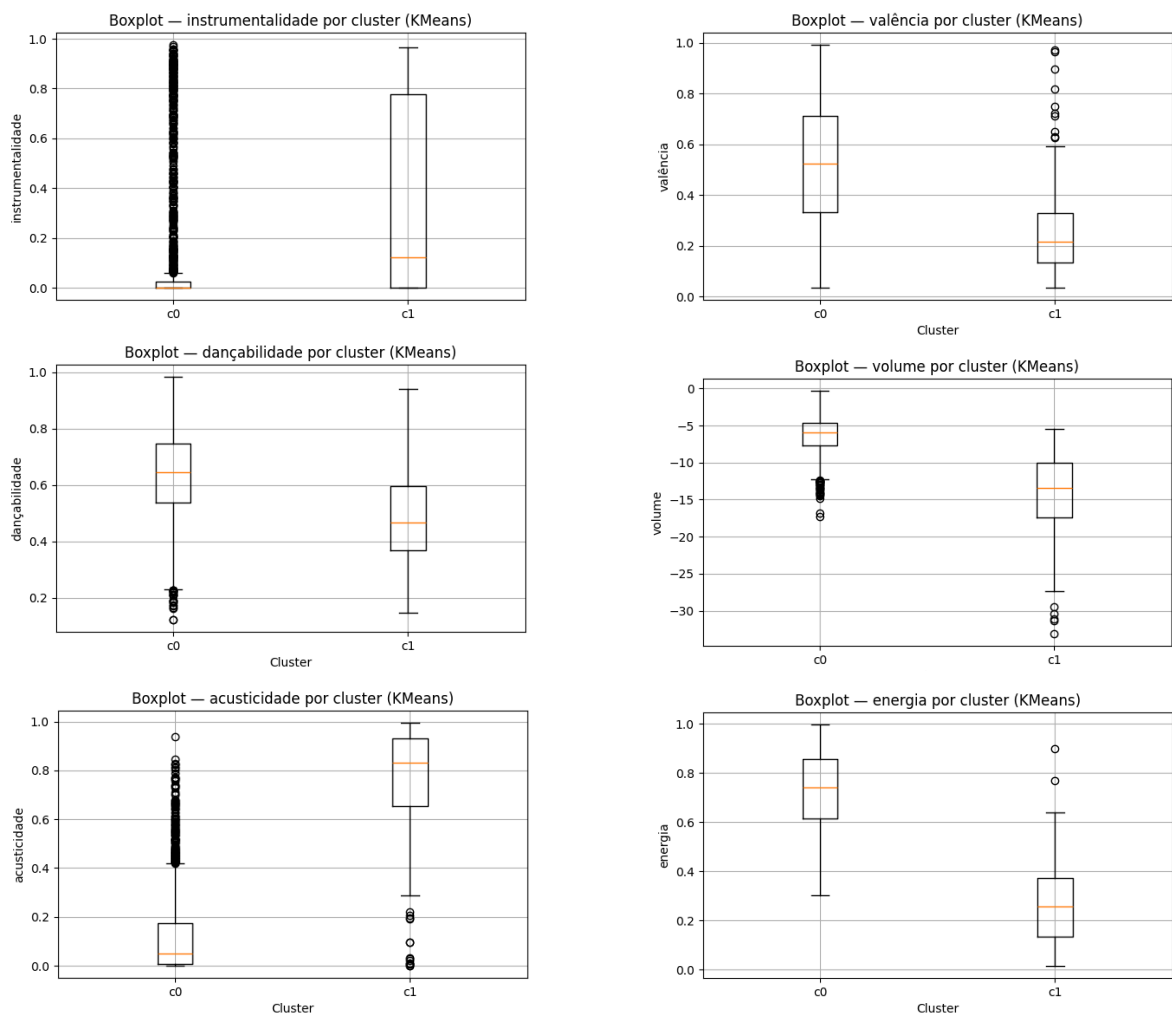
O gráfico *Boxplot* —  $\{feat\}$  por cluster (*K-Means*) ilustra a variação de cada atributo de áudio entre os diferentes grupos formados pelo algoritmo de clusterização. Cada boxplot representa a distribuição de um atributo específico, como dançabilidade, energia, acusticidade ou volume, em todos os clusters gerados. Assim, é possível observar como o valor desse atributo se comporta dentro de cada grupo, destacando medianas, dispersões e possíveis outliers.

Por exemplo, ao analisar o boxplot da dançabilidade, é possível identificar se há algum cluster composto majoritariamente por músicas mais dançantes, enquanto outros apresentam valores menores para essa característica. Esse tipo de gráfico é especialmente útil para visualizar diferenças e semelhanças entre os clusters, permitindo comparar os perfis médios de cada grupo.

Na interpretação, os boxplots ajudam a compreender quais atributos definem melhor cada cluster. Um grupo que apresenta altos valores de energia e volume pode corresponder a músicas eletrônicas ou agitadas, enquanto outro, com maior acusticidade e menor dançabilidade, pode representar faixas mais calmas e acústicas.

No contexto das músicas, esse gráfico é essencial para rotular e descrever os clusters identificados. Por exemplo: Cluster 0: acústico e calmo; Cluster 1: energético e dançante; Cluster 2: instrumental e técnico

Dessa forma, os boxplots traduzem as informações numéricas do modelo em características sonoras compreensíveis, facilitando a análise e a interpretação dos perfis musicais presentes no conjunto de dados.



## Dendrograma (Hierarchical Clustering)


O gráfico *Dendrograma (amostra)* representa visualmente a hierarquia de semelhança entre as músicas analisadas pelo método de agrupamento hierárquico. Nesse tipo de gráfico, cada linha ou “ramo” conecta músicas (ou grupos de músicas) de acordo com seu grau de similaridade sonora. As junções mais próximas da base do gráfico indicam pares ou grupos de músicas com características acústicas muito semelhantes,

enquanto as junções mais altas correspondem a grupos que só se unem quando a similaridade entre eles é menor.

A altura das junções é um elemento-chave na interpretação: quanto menor a altura, maior a semelhança entre as músicas ou clusters conectados naquele ponto. Esse comportamento permite observar, de maneira intuitiva, como os grupos se formam e se relacionam entre si.

Na prática, o dendrograma pode ser “cortado” em diferentes alturas para definir o número de clusters desejados. Um corte mais baixo forma muitos grupos pequenos e homogêneos, enquanto um corte mais alto gera poucos clusters mais amplos e diversificados. Essa flexibilidade ajuda a comparar a granularidade dos agrupamentos e a compreender as relações entre estilos musicais distintos.

No contexto das músicas, o dendrograma revela como os estilos e perfis sonoros se conectam. Por exemplo, músicas pop e eletrônicas podem aparecer próximas em um mesmo ramo, indicando características compartilhadas como alta energia e dançabilidade. Já músicas acústicas e instrumentais podem se agrupar em outro ramo, sugerindo timbres e estruturas semelhantes. Dessa forma, o gráfico funciona como um mapa hierárquico das similaridades sonoras, facilitando a visualização das relações entre os diferentes tipos de faixas presentes no conjunto de dados.




## Scatter Plot (PCA) — Hierarchical Clustering

O gráfico *Hierarchical* ( $n\_clusters = \text{valor ótimo}$ ) — *projeção PCA* apresenta os agrupamentos formados pelo algoritmo de Clusterização Hierárquica (Ward), projetados em um plano bidimensional por meio da Análise de Componentes Principais (PCA). Assim como no gráfico do K-Means, cada ponto representa uma música, e as cores indicam o cluster ao qual ela pertence, mas, neste caso, os grupos foram definidos pelo método hierárquico em vez do particional.

O objetivo desta visualização é comparar o resultado do agrupamento hierárquico com o do K-Means, verificando se os dois métodos produzem divisões semelhantes ou se o modelo hierárquico cria fronteiras diferentes entre os grupos. O gráfico permite observar se há separações nítidas entre os clusters, se eles se sobrepõem ou se certas músicas ficam mais próximas de estilos diferentes, o que ajuda a entender a coerência das fronteiras criadas pelo algoritmo.

No contexto musical, esse gráfico mostra se o método hierárquico é capaz de distinguir os mesmos estilos sonoros identificados pelo K-Means ou se ele propõe uma organização alternativa das faixas. Por exemplo, o Hierarchical Clustering pode agrupar músicas eletrônicas e pop em um mesmo cluster por apresentarem timbres e ritmos semelhantes, enquanto o K-Means pode separá-las em grupos distintos. Dessa forma, essa visualização complementa a análise, permitindo comparar diferentes abordagens de agrupamento e compreender melhor como os estilos musicais se distribuem e se relacionam dentro do conjunto de dados.



### Outras saídas de texto

O script também exibe:

- Tabela de médias por cluster (K-Means e Hierarchical): mostra o perfil numérico médio de cada grupo (essencial para interpretar os clusters).
- Silhouette Scores: compara o desempenho entre os dois métodos (quanto maior, melhor separação).